(1.) Сначала рассчитаем Peak memory.

Она состоит из: input batch + model weights + peak activation + буфер памяти для cuBLAS + буфер памяти для cuBLASt.

(Запускал на T4 видеокарте)

Рассчитаем вес модели: Pooling и Relu ничего не весят.

Формула для Conv слоёв: 4 · input_channels · output_channels · filter_size², (4 потому что в байтах)

Conv 7×7 3→32: 4·3·32·7² = 18 816.

Рассчитал так все слои, получили 3 533 184 байта.

Размер линейного слоя: input_dim · (output_dim + 1) (с bias)

Размер лин. слоёв: 628 112. **Размер модели: 4 161 296 байт**

Размер input = 3 · S² · B

Peak activation достигается при подсчёте Max Pool 1-ого слоя, так как мы одновременно держим в памяти результат 1-ого Conv слоя, индексы для подсчёта Max Pool, и сам результат Max Pool. **Формула Peak activation:** $\underbrace{B \cdot 32 \cdot \left(\frac{S}{2}\right)^2 \cdot 4}_{\text{Conv}} + B \cdot 32 \cdot \left(\frac{S}{4}\right)^2 \cdot 4 + B \cdot 32 \cdot \left(\frac{S}{4}\right)^2 \cdot 8 = \mathbf{56 B \cdot S^2}$

(+ Max Pool result. + Max Pool idx (int64))

буфер для cuBLAS + cuBLASt = 8 519 680 (8,125 МБ) + 1 048 576 (1 МБ) = **9 568 256 байт**

Формула Peak memory = сумма всего в квадратиках = 13 729 792 + 68 · B · S² + Δ(S, B)

Δ – доп. выделения памяти для алгоритмов свёртки.

Для 15 % всех измерений формула верна до байта.

Но в основном формула занижает реальные значения на ≈20 %

ООМ случай при S = 1024, B = 256. По формуле получили 17 421 МБ ≈ 17 ГБ.

② Считаем FLOPS.

Для Conv слоя: $B \cdot output_size^2 \cdot output_channels \cdot input_channels \cdot 2 \cdot filter_size^2$.

Применяем окно свёртки n раз, где $n = B \cdot output_size^2 \cdot output_channels \cdot input_channels$

На каждое применение окна требует $filter_size^2$ MAC, что равно $2 \cdot filter_size^2$ FLOPS.

Для лин. слоя: $2 \cdot B \cdot input_dim \cdot (output_dim + 1)$ FLOPS. $\geq 313700 \cdot B$

[illegible]

Global avg pooling: для каждого канала по $input_size^2$ сложений. Т.е. $= B \cdot 512 \left(\frac{S}{16}\right)^2$ FLOPS (одним делением можно пренебречь)

В итоге получаем $\boxed{F = 17714 \cdot S^2 \cdot B + 313700 \cdot B.}$

③ Считаем latency

Для latency нужно посчитать кол-во операций чтения и записи байтов.

~~Для свёртки: $4 \cdot (B \cdot S^2 \cdot input_channels + \dots$~~

Для свёртки: $4 \cdot (B \cdot input_channels \cdot input_size^2 + input_channels \cdot output_channels \cdot filter_size^2 + B \cdot output_channels \cdot output_size^2)$

Семантика: чтение входа + чтение весов + запись выхода.

Для ReLU: $4 \cdot B \cdot input_size^2 \cdot channels + 4 \cdot B \cdot input_size^2 \cdot channels$.

Для linear: $4 \cdot (B \cdot input_size + input_size \cdot output_size + output_size + B \cdot output_size)$

bias

Для MaxPool: $\underbrace{4 \cdot B \cdot \left(\frac{S}{2}\right)^2 \cdot 32}_{\text{читаем input}} + \underbrace{4 \cdot B \cdot \left(\frac{S}{4}\right)^2 \cdot 32}_{\text{пишем output}} + \underbrace{8 \cdot B \cdot \left(\frac{S}{4}\right)^2 \cdot 32}_{\text{записываем индексы int64}}$

Для Global AVG Pool: $4 \cdot B \cdot channels \cdot input\text{-}size^2 + 4 \cdot B \cdot channels$

Семантика: читаем input + записываем среднее в каждый канал.

Всего в нейросети 17 слоёв. Каждый слой имеет FLOPS(F) и Read/Write (D).

Формула Latency: $17\Theta_1 + \sum_{i=1}^{17} \max\left(\frac{F_i(S,B)}{\Theta_2}, \frac{D_i(S,B)}{\Theta_3}\right)$

$\Theta = (\Theta_1, \Theta_2, \Theta_3)$. Θ_1 - Затраты torch на синхронизацию.

Θ_2 - скорость 1 FLOPS операции, Θ_3 - скорость 1 Read/Write операции. Всего Read/Write операций: $D(S,B) = 4161296 + 3780B\,S^2 + 8592B$.

(4.) Энергия: $\Theta_1 + \Theta_2 \cdot F(S,B) + \Theta_3 \cdot D(S,B)$

Θ_1 - затраты на инициализацию и т.п.

Θ_2 - Энергия одной FLOPS операции.

Θ_3 - Энергия одной Read/Write операции.